

# Raport

## Sieci Neuronowe w Histopatologii

### Anomaly Detection

Wojciech Kosiuk  
Politechnika Warszawska

Szymon Matuszewski  
Politechnika Warszawska

Michał Mazuryk  
Politechnika Warszawska

Tomasz Modzelewski  
Politechnika Warszawska

Tymoteusz Urban  
Politechnika Warszawska

27 maja 2023

## Spis treści

|  |          |
|--|----------|
| <b>1 Wstęp</b>                           | <b>1</b> |
| <b>2 Anomaly Detection</b>               | <b>2</b> |
| <b>3 Algorytmy PO Ekstrakcji Cech</b>    | <b>2</b> |
| 3.1 Zdjęcia RGB                          | 2        |
| 3.1.1 Model Sigmoid oraz ImageNet        | 2        |
| 3.1.2 Model Boosting                     | 2        |
| 3.1.3 Model z Warstwy Konwolucyjnej      | 2        |
| 3.1.4 Model z Autoencoderem              | 2        |
| 3.2 Zdjęcia Czarnobiałe                  | 2        |
| 3.2.1 Model Sigmoid oraz ImageNet        | 3        |
| 3.2.2 Model Boosting                     | 3        |
| 3.2.3 Model z Warstwy Konwolucyjnej      | 3        |
| 3.2.4 Model z Autoencoderem              | 3        |
| <b>4 Algorytmy PRZED Ekstrakcją Cech</b> | <b>4</b> |
| <b>5 Wnioski</b>                         | <b>4</b> |
| <b>6 Podsumowanie</b>                    | <b>4</b> |

## 1 Wstęp

Poniższa praca stanowi raport przygotowany na Warsztaty Badawcze prowadzone na Wydziale Matematyki i Nauk Informacyjnych Politechniki Warszawskiej w roku akademickim 2022/23 w semestrze letnim. Zagadnienie nad jakim pracowaliśmy to Anomaly Detection na zdjęciach histopatologicznych. Biorąc pod uwagę podejście medyczne anomalią przyjętą przez nas jest komórka rakowa. W celu ich wykrycia zastosowaliśmy dwa podejścia:

1. Algorytmy PO ekstrakcji cech ze zdjęcia,
2. Algorytmy PRZED ekstrakcją cech ze zdjęcia.

## 2 Anomaly Detection

## 3 Algorytmy PO Ekstrakcji Cech

### 3.1 Zdjęcia RGB

#### 3.1.1 Model Sigmoid oraz ImageNet

#### 3.1.2 Model Boosting

#### 3.1.3 Model z Warstwy Konwolucyjnej


#### 3.1.4 Model z Autoencoderem

### 3.2 Zdjęcia Czarnobiałe

Postanowiliśmy zastosować identyczne podejście również do zdjęć w skali szarości. Chcieliśmy sprawdzić hipotezę, czy anomalie w powyższych algorytmach wykrywane są w dużej zależności od koloru tkanki. Niektóre źródła, takie jak [1], sugerują na poprawę jakości modeli klasyfikujących zdjęcia medyczne po transformacji tych zdjęć na czarnobiałe.

Kroki, które poczyniliśmy w celu transformacji zdjęć histopatologicznych w skalę szarości:

1. Zamiana zdjęć **RGB** na **grayscale** (skala szarości).
2. Transformacja **CLAHE** zdjęć **grayscale**.
3. Rozszerzenie wymiaru kolorów poprzez powtórzenie czarnobiałego wymiaru - *repeat expand dims*, w celu imitacji obrazu RGB wymaganego przez algorytmy.



Rysunek 1: Na rysunku kolejne etapy transformacji: wiersz górny - zdjęcia RGB, wiersz środkowy - grayscale, wiersz dolny - CLAHE. Zdjęcia do prezentacji zostały wylosowane.

Efekty transformacji możemy zauważyć na rysunku 1. Jak widzimy transformacja Adaptive Histogram Equalization nie wprowadza drastycznych zmian dla oka, jednak może mieć wpływ na jakość modeli.

### 3.2.1 Model Sigmoid oraz ImageNet

|           | Sigmoid | ImageNet |
|-----------|---------|----------|
| Accuracy  | 0.50    | 0.85     |
| Precision | 0       | 0        |
| Recall    | 0       | 0        |
| F1 Score  | 0       | 0        |

Tabela 1: Tabela przedstawia wyniki modeli na zdjęciach po transformacji grayscale oraz CLAHE. Liczba epoch obydwu modeli wynosi 25.

Model sigmoid, tak jak dla zdjęć RGB był obliczany dla proporcji 0.5 komórek zdrowych do wszystkich komórek. Chcieliśmy, aby porównanie względem zdjęć kolorowych było sprawiedliwe. ImageNet z kolei, analogicznie był tworzony dla proporcji 0.85. Wyniki na zbiorze walidacyjnym prezentujemy w tabeli 1. Oba modele nie były w stanie nauczyć się wykrywania anomalii. Transformacje w tym przypadku nie przynosiły zadowalających rezultatów.

### 3.2.2 Model Boosting

|           | Isolation<br>Forest | Local<br>Outlier<br>Factor | One-Class<br>SVM | Voting |
|-----------|---------------------|----------------------------|------------------|--------|
| Accuracy  | 0.67                | 0.68                       | 0.66             | 0.68   |
| Precision | 0.12                | 0.17                       | 0.12             | 0.14   |
| Recall    | 0.20                | 0.29                       | 0.19             | 0.20   |

Tabela 2: Tabela przedstawia wyniki algorytmów Anomaly Detection mających na celu poprawić jakość wykrywania komórek rakowych na zbiorze walidacyjnym.

W celu sprawdzenia algorytmów Anomaly Detection poprawiających jakość wykrywania komórek rakowych przeprowadziliśmy analogiczne rozumowanie jak w przypadku zdjęć RGB. W tym przypadku stosunek komórek zdrowych do wszystkich komórek był równy 0.85. Wyniki przedstawione są w tabeli 2. W porównaniu do rozwiązania ze zdjęciami kolorowymi nie daje to pozytywnych rezultatów.

### 3.2.3 Model z Warstwy Konwolucyjnej

|           | Isolation<br>Forest | Local<br>Outlier<br>Factor | One-Class<br>SVM | Voting |
|-----------|---------------------|----------------------------|------------------|--------|
| Accuracy  | 0.81                | 0.80                       | 0.82             | 0.90   |
| Precision | 0.01                | 0.01                       | 0.03             | 0.02   |
| Recall    | 0.05                | 0.18                       | 0.09             | 0.05   |

Tabela 3: Tabela przedstawia wyniki algorytmów wykrywających anomalie z ostatniej warstwy konwolucyjnej na zbiorze walidacyjnym. Jak widzimy algorytmy te nie były w stanie wykrywać komórek rakowych.

Zastosowanie algorytmów Anomaly Detection na ostatniej warstwie konwolucyjnej również nie przyniosło zadowalających efektów. Wyniki przedstawione są na tabeli 3.

### 3.2.4 Model z Autoencoderem

Analogiczne rozumowanie w przypadku zastosowania Autoencodera przeprowadziliśmy w przypadku zdjęć czarno-białych. Wytrenowany Autoencoder posiadał SSIM Score na poziomie 0.75, więc możemy go uznać za całkiem reprezentatywny.

|           | Isolation<br>Forest | Local<br>Outlier<br>Factor | One-Class<br>SVM | Voting |
|-----------|---------------------|----------------------------|------------------|--------|
| Accuracy  | 0.74                | 0.71                       | 0.72             | 0.76   |
| Precision | 0.16                | 0.05                       | 0.12             | 0.14   |
| Recall    | 0.17                | 0.05                       | 0.13             | 0.12   |

Tabela 4: Tabela przedstawia wyniki modeli Anomaly Detection po zastosowaniu autoencodera na zdjęciach po transformacjach grayscale oraz CLAHE.

## 4 Algorytmy PRZED Ekstrakcją Cech

## 5 Wnioski

- Transformacja zdjęć na czarno-białe nie wspomogła algorytmów Anomaly Detection w wykrywaniu komórek rakowych. Kolor zdjęcia (komórki) jest wykorzystywany przez te algorytmy w określeniu anomalii.

## 6 Podsumowanie

## Literatura

- [1] Pre-training on grayscale imagenet improves medical image classification. [https://openaccess.thecvf.com/content\\_ECCVW\\_2018/papers/11134/Xie\\_Pre-training\\_on\\_Grayscale\\_ImageNet\\_Improves\\_Medical\\_Image\\_Classification\\_ECCVW\\_2018\\_paper.pdf?fbclid=IwAR2MN3WcLmLaa8Ro0FTIVn3s0YyQ5\\_C99AVmaRh1Wv1LQJSk7l0\\_4f\\_pV2E](https://openaccess.thecvf.com/content_ECCVW_2018/papers/11134/Xie_Pre-training_on_Grayscale_ImageNet_Improves_Medical_Image_Classification_ECCVW_2018_paper.pdf?fbclid=IwAR2MN3WcLmLaa8Ro0FTIVn3s0YyQ5_C99AVmaRh1Wv1LQJSk7l0_4f_pV2E), author=Yiting Xie and David Richmond.